

LAPORAN *PROJECT*
MATA KULIAH MACHINE LEARNING



Kelompok H

Statistika A

Nama Anggota:

1. Verdina Tista Pudyawardhana (K1D024002)
2. Nabila Alsa Haryanto (K1D024006)
3. Frisca Putri Aulia (K1D024008)
4. Wuri Dwi Ariyanti (K1D024025)
5. Dionisius Antoni Pratama (K1D024031)

KEMENTERIAN PENDIDIKAN TINGGI, SAINS DAN TEKNOLOGI

UNIVERSITAS JENDERAL SOEDIRMAN

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

S1 STATISTIKA

2026

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi yang masif dalam beberapa dekade terakhir telah membawa perubahan signifikan di berbagai sektor kehidupan, tidak terkecuali pada sektor pendidikan. Integrasi teknologi seperti Kecerdasan Buatan (*Artificial Intelligence*) dan pembelajaran mesin (*Machine Learning*) kini tidak lagi sebatas alat bantu administratif, melainkan telah merambah pada optimalisasi proses belajar-mengajar dan pengambilan keputusan strategis bagi institusi pendidikan. Salah satu penerapan *machine learning* yang saat ini menarik perhatian besar adalah pemodelan prediktif untuk mengukur prestasi akademik siswa.

Kemampuan untuk memprediksi nilai ujian siswa sejak dini memiliki urgensi yang sangat tinggi. Bagi institusi pendidikan, hasil prediksi ini dapat berfungsi sebagai sistem peringatan dini (*early warning system*) untuk mengidentifikasi siswa yang berisiko mengalami kegagalan akademis atau penurunan performa. Dengan adanya informasi prediktif tersebut, pihak sekolah maupun tenaga pendidik dapat merancang dan mengimplementasikan intervensi yang tepat sasaran—seperti program bimbingan belajar tambahan atau konseling—sebelum ujian akhir berlangsung. Pada akhirnya, langkah preventif ini berkontribusi langsung terhadap peningkatan kualitas pembelajaran dan angka kelulusan secara keseluruhan.

Namun, memprediksi prestasi akademik bukanlah perkara yang mudah mengingat faktor-faktor yang mempengaruhinya sangat beragam dan saling terkait. Faktor tersebut tidak hanya terbatas pada aspek akademis murni, tetapi juga mencakup pola hidup dan interaksi siswa dengan teknologi modern. Di satu sisi, variabel seperti jumlah jam belajar, tingkat kehadiran di kelas, dan intensitas penyelesaian tugas sekolah secara intuitif menjadi pilar utama penentu keberhasilan. Di sisi lain, faktor non-akademis seperti durasi tidur yang merepresentasikan kualitas istirahat, hingga tingkat penggunaan internet yang mencerminkan gaya hidup digital, turut memberikan dampak yang tidak kalah besar terhadap kesiapan mental dan fisik siswa dalam menghadapi ujian.

Dalam upaya memetakan kompleksitas hubungan antar variabel tersebut, penelitian ini memanfaatkan sebuah dataset yang komprehensif mencakup 1.999 data

siswa. Dataset ini mengintegrasikan berbagai prediktor penting, antara lain jam belajar (*study_hours*), tingkat kehadiran (*attendance*), jam tidur (*sleep_hours*), penggunaan internet (*internet_usage*), tugas yang diselesaikan (*assignments_completed*), nilai sebelumnya (*previous_score*), dan status penempatan (*placement_status*), dengan variabel target berupa nilai ujian (*exam_score*). Untuk membangun model prediksi yang kuat (*robust*), metode *Random Forest Regression* dan beberapa metode regresi lainnya dipilih sebagai pendekatan dalam penelitian ini. Algoritma *Random Forest Regression* ini merupakan teknik *ensemble learning* yang bekerja dengan cara menggabungkan banyak pohon keputusan (*decision trees*) untuk menghasilkan satu prediksi akhir yang didasarkan pada nilai rata-rata. Pemilihan *Random Forest Regression* didasari oleh keunggulannya yang terbukti sangat efektif dalam menangani dataset dengan banyak fitur, memiliki ketahanan yang tinggi terhadap gejala *overfitting*, serta mampu menghasilkan informasi tingkat kepentingan fitur (*feature importance*). Fitur interpretasi inilah yang menjadi nilai tambah krusial, karena tidak hanya sekadar memberikan angka prediksi nilai, tetapi juga mampu menjabarkan faktor mana saja yang paling dominan dalam mempengaruhi prestasi akademik siswa. Demikian, sekaligus akan dievaluasi model terbaik, antara metode *Regression Forest Regression* dan beberapa metode regresi lainnya.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah :

1. Bagaimana membangun model prediksi nilai ujian siswa menggunakan metode regresi?
2. Seberapa akurat model *Random Forest Regression* dibanding dengan metode regresi lainnya dalam memprediksi nilai ujian siswa berdasarkan dataset yang tersedia?
3. Faktor-faktor (fitur) apa yang paling berpengaruh terhadap nilai ujian siswa berdasarkan analisis *feature importance*?

1.3 Tujuan Penelitian

Tujuan dari penelitian yang dilakukan yaitu adalah :

1. Membangun model prediksi nilai ujian siswa menggunakan metode regresi.

2. Mengevaluasi performa model regresi menggunakan metrik MAE, RMSE, dan *R-squared*.
3. Mengidentifikasi fitur-fitur yang paling berpengaruh terhadap prediksi nilai ujian melalui analisis feature importance.

1.4 Manfaat Penelitian

Manfaat yang didapatkan melalui penelitian yang dilakukan adalah :

1. Dapat membangun model prediksi nilai ujian siswa menggunakan metode regresi.
2. Dapat mengevaluasi performa model menggunakan metrik MAE, RMSE, dan *R-squared* untuk mengukur besar kesalahan prediksi tingkat kemampuan model dalam menjelaskan variasi data secara keseluruhan.
3. Dapat mengidentifikasi fitur-fitur yang paling berpengaruh terhadap prediksi nilai ujian melalui analisis feature importance.

BAB II

TINJAUAN DATASET

2.1. Sumber Dataset

Dataset yang digunakan dalam proyek Machine Learning ini merupakan data sekunder yang diperoleh dari platform repositori data publik, yaitu Kaggle. Dataset ini berjudul “*Student Performance Dataset*” dan dirancang untuk menggambarkan berbagai faktor yang dapat memengaruhi pencapaian akademik siswa, seperti kebiasaan belajar, durasi tidur, tingkat partisipasi dalam kegiatan belajar, serta penggunaan sarana digital dalam proses pembelajaran.

Selain itu, dataset ini juga memuat berbagai variabel pendukung lain yang berkaitan dengan kondisi belajar siswa, sehingga dapat memberikan gambaran yang cukup komprehensif mengenai faktor-faktor yang berpotensi memengaruhi hasil akademik. Data yang digunakan terdiri dari sejumlah besar observasi terstruktur, sehingga memungkinkan penerapan teknik machine learning, khususnya model regresi, secara lebih representatif dan stabil. Pemilihan dataset ini didasarkan pada kesesuaiannya dengan tujuan analisis prediktif, di mana hubungan antar variabel dapat dimodelkan untuk mengestimasi performa akademik siswa berdasarkan faktor-faktor yang tersedia dalam data.

2.2. Deskripsi Dataset

Dataset ini berisi data dari 1.999 observasi siswa, dengan 7 fitur independen sebagai variabel prediktor dan 1 variabel dependen sebagai target. Data ini digunakan untuk melihat hubungan antara berbagai faktor terhadap hasil akademik siswa melalui pendekatan statistik. Variabel-variabel yang digunakan terdiri dari data berskala metrik serta data non-metrik seperti kategorikal nominal dan biner. Kombinasi jenis data ini memungkinkan analisis yang lebih beragam dalam proses pemodelan. Penjelasan mengenai struktur variabel, tipe data pada bahasa pemrograman, serta definisi operasional masing-masing variabel disajikan secara rinci pada tabel berikut.

Variabel	Tipe Data	Skala/Jenis	Keterangan
----------	-----------	-------------	------------

study_hours	Integer	Rasio	Akumulasi durasi waktu belajar mandiri yang dihabiskan siswa di luar jam sekolah formal, diukur dalam satuan jam per minggu.
attendance	Integer	Rasio	Persentase kehadiran fisik siswa di dalam ruang kelas selama 1 semester penuh.
sleep_hours	Integer	Rasio	Rata-rata kuantitas durasi waktu istirahat atau tidur malam siswa secara reguler, diukur dalam satuan jam per hari.
internet_usage	Integer	Interval	Skor indeks atau representasi kuantitatif pemanfaatan jaringan internet oleh siswa untuk aktivitas harian atau pendukung pembelajaran.
assigments_completed	Integer	Rasio	Jumlah total tugas sekolah, pekerjaan rumah, maupun proyek

			terstruktur yang diselesaikan dan dikumpulkan oleh siswa selama semester berjalan.
previous_score	Integer	Rasio	Nilai evaluasi atau capaian performa akademik kumulatif yang diperoleh siswa pada periode ujian atau semester sebelumnya.
placement_status	String/Object	Nominal	Status penempatan program atau kelayakan kelas siswa, dikategorikan secara biner menjadi dua kelompok Placed dan Not Placed.
exam_score	Float	Rasio	Nilai ujian akhir siswa berskala kontinu yang mencerminkan hasil belajar aktual dan bertindak sebagai variabel respons utama yang diprediksi.

2.3. Jenis Masalah

Berdasarkan analisis karakteristik dataset, penelitian ini secara tegas termasuk dalam permasalahan regresi, bukan klasifikasi. Hal ini didasarkan pada sifat variabel target yaitu *exam_score*, yang berbentuk numerik kontinu. Dalam statistika, metode klasifikasi hanya digunakan ketika target berupa kategori diskrit dan terbatas, misalnya “lulus” atau “tidak lulus”. Sementara itu, *exam_score* merupakan nilai numerik pada skala rasio yang berada pada rentang kontinu, yaitu sekitar 26.89 hingga 100.00, sehingga lebih tepat dimodelkan menggunakan pendekatan regresi. Selain itu, tujuan utama penelitian ini adalah membangun fungsi prediksi yang dapat memetakan berbagai variabel input—seperti jam belajar, tingkat kehadiran, durasi tidur, penggunaan internet, jumlah tugas, nilai ujian sebelumnya, dan status penempatan—untuk memperkirakan nilai ujian siswa secara akurat. Jika masalah ini dipaksa menjadi klasifikasi, maka informasi detail mengenai variasi nilai siswa akan hilang karena harus dikelompokkan ke dalam kelas-kelas tertentu. Oleh karena itu, pendekatan regresi dipilih agar model tetap mampu menangkap perubahan kecil pada setiap variabel terhadap hasil akhir secara lebih sensitif dan akurat.

BAB III

METODOLOGI

3.1. Alur Kerja Penelitian

Penelitian ini dilaksanakan melalui serangkaian tahapan sistematis untuk membangun dan mengevaluasi model prediksi nilai ujian mahasiswa. Tahapan-tahapan tersebut meliputi pengumpulan data, eksplorasi data, prapemrosesan data, pemodelan, evaluasi model, serta analisis dan interpretasi hasil.

1. Pengumpulan Data

Data diperoleh dari dataset `student_performance.csv` yang berisi 1.999 observasi dengan 8 kolom. Dataset ini mencakup variabel-variabel seperti durasi belajar (`study_hours`), kehadiran (`attendance`), durasi tidur (`sleep_hours`), penggunaan internet (`internet_usage`), jumlah tugas diselesaikan (`assignments_completed`), nilai sebelumnya (`previous_score`), nilai ujian (`exam_score`), dan status penempatan (`placement_status`). Data dimuat menggunakan library Pandas untuk analisis lebih lanjut.

2. Eksplorasi Data (EDA)

Setelah data berhasil dikumpulkan, dilakukan eksplorasi data secara mendalam untuk memahami pola dan karakteristik data. Tahap ini mencakup analisis statistik deskriptif untuk mengetahui mean, median, standar deviasi, dan distribusi setiap variabel. Visualisasi data dilakukan menggunakan histogram, boxplot, scatter plot, dan heatmap korelasi untuk mengidentifikasi hubungan antar variabel serta mendeteksi missing values, duplikat, dan outlier.

3. Prapemrosesan Data

Tahap prapemrosesan data bertujuan untuk membersihkan dan mempersiapkan data sebelum pemodelan. Langkah pertama adalah memeriksa dan menangani missing values, kemudian mendeteksi outlier menggunakan metode IQR (Interquartile Range). Variabel kategorik diubah menjadi format numerik melalui proses encoding. Setelah itu, data dibagi menjadi data latih (80%) dan data uji (20%)

dengan `random_state=42`. Terakhir, fitur numerik diskalakan menggunakan `StandardScaler` agar memiliki skala yang seragam, sehingga model dapat belajar secara optimal.

4. Pemodelan

Pada tahap ini, dibangun beberapa model machine learning untuk memprediksi nilai ujian mahasiswa. Model-model yang digunakan meliputi Baseline Model, Linear Regression, Decision Tree Regressor, dan Random Forest Regressor. Pada Random Forest Regressor, dilakukan hyperparameter tuning menggunakan `GridSearchCV` dengan 5-fold cross-validation untuk menemukan kombinasi parameter optimal. Parameter yang di-tuning meliputi `n_estimators`, `max_features`, `max_depth`, dan `min_samples_leaf`.

5. Evaluasi Model

Setelah model dilatih, dilakukan evaluasi kinerja menggunakan metrik yang sesuai untuk masalah regresi. Metrik yang digunakan adalah Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), dan R-squared (R^2). Evaluasi dilakukan pada testing set yang tidak digunakan selama proses training untuk mengukur kemampuan generalisasi model. Selain itu, dilakukan analisis residual dan visualisasi prediksi vs aktual.

6. Analisis dan Interpretasi

Tahap akhir meliputi analisis hasil pemodelan dan interpretasi temuan. Feature importance dari Random Forest Regressor dianalisis untuk mengidentifikasi faktor-faktor yang paling berpengaruh. Hasil evaluasi dari ketiga model dibandingkan untuk menentukan model terbaik. Diskusi mengenai kemungkinan overfitting atau underfitting pada model juga dilakukan pada tahap ini.

3.2. Eksplorasi Data

3.2.1. Statistik deskriptif

Statistik deskriptif digunakan untuk mendeskripsikan hasil temuan pada data. Hasil temuan tersebut digunakan untuk menggambarkan data secara umum, terutama pada variabel numerik. Melalui statistik deskriptif, dapat dilihat nilai

rataan hitung (mean), sebaran data atau standar deviasi, nilai data terkecil, nilai data terbesar, dan kuartil data numerik. Dalam python, dapat menggunakan sintaks `.describe()` untuk melihat statistik deskriptif dataset.

Fungsi `describe()` akan menghasilkan ringkasan statistik untuk fitur numerik dalam dataset. Beberapa informasi yang ditampilkan antara lain count, mean, std, min, 25%, 50%, 75%, dan max. Nilai count menunjukkan jumlah data yang tersedia, mean menunjukkan nilai rata-rata, std menunjukkan standar deviasi, min menunjukkan nilai terkecil, sedangkan max menunjukkan nilai terbesar. Sementara itu, nilai 25%, 50%, dan 75% menunjukkan posisi kuartil data.

Jika dimasukkan parameter `include = "object"`, output akan menjelaskan fitur kategorik dalam dataset. Demikian statistik deskriptif membantu untuk menjelaskan gambaran umum mengenai dataset.

3.2.2. Analisis distribusi variabel

Analisis distribusi variabel dapat digunakan untuk menggambarkan sebaran data. Analisis distribusi termasuk dalam kategori visualisasi data. Visualisasi data sangat bermanfaat untuk melihat distribusi dan sebaran variabel numerik. Visualisasi distribusi variabel, terutama variabel numerik, dapat menggunakan histogram.

Visualisasi data menggunakan histogram dimanfaatkan pada data yang berskala interval atau rasio. Setiap batang pada histogram mewakili rentang nilai tertentu, sedangkan tinggi batang menunjukkan jumlah atau frekuensi data yang berada pada rentang tersebut. Melalui visualisasi ini, pola sebaran data dapat terlihat lebih jelas, terutama untuk mengetahui apakah data cenderung terkumpul pada nilai rendah, sedang, atau tinggi.

3.2.3. Analisis korelasi antar variabel

Analisis korelasi antar variabel digunakan untuk melihat korelasi antar variabel. Analisis korelasi antar variabel diperlukan untuk melihat multikolinearitas antar variabel independen. Jika terjadi multikolinearitas yang tinggi antar variabel independen, variabel tersebut dapat direduksi dengan PCA atau di buang.

Visualisasi matriks korelasi dapat menggunakan heatmap matriks. Untuk melihat korelasi antar variabel independen, dapat menggunakan sintaks `.corr()`

Heatmap matriks korelasi digunakan untuk melihat hubungan antarvariabel numerik dalam dataset. Korelasi menunjukkan seberapa kuat hubungan antara satu variabel dengan variabel lainnya. Nilai korelasi berada pada rentang -1 sampai 1. Nilai mendekati 1 menunjukkan hubungan positif yang kuat, nilai mendekati -1 menunjukkan hubungan negatif yang kuat, sedangkan nilai mendekati 0 menunjukkan hubungan yang lemah atau tidak terdapat hubungan linear yang jelas.

3.2.4. Identifikasi missing value dan duplikat

Pemeriksaan nilai kosong atau missing value dilakukan untuk mengetahui apakah terdapat data yang belum terisi. Pemeriksaan nilai missing value atau nilai kosong dapat menggunakan sintaks `isna()` yang menghasilkan logical value, kemudian hasil tersebut dijumlah dengan `.sum()`.

Data duplikat perlu diperiksa untuk memastikan tidak ada baris data yang muncul lebih dari satu kali. Pengecekan redundansi data diperlukan, terutama pada dataset yang memiliki “id”.

3.2.5. Identifikasi outlier

Kemudian, dapat dilihat pencilat atau *outlier* pada kolom data numerik dengan menggunakan boxplot. Titik-titik yang berada di luar garis terluar merupakan pencilat yang berpotensi untuk menurunkan performa model. Untuk membersihkan pencilat, dapat menggunakan metode IQR atau menggunakan metode lainnya seperti transformasi (logaritma, akar, robust, dll).

Teknik Interquartile Range (IQR) merupakan salah satu metode yang digunakan untuk mengidentifikasi data pencilan atau outlier, yang umumnya divisualisasikan melalui diagram box plot. Suatu nilai pada fitur tertentu dikategorikan sebagai outlier apabila nilainya berada di luar rentang batas bawah;

$$Q_1 - 1.5 \cdot IQR$$

dan batas atas;

$$Q_3 + 1.5 \cdot IQR$$

Nilai yang berada di bawah batas bawah atau di atas batas atas dianggap sebagai data pencilan karena memiliki jarak yang cukup jauh dari sebaran mayoritas data. Pada beberapa kasus, *outlier* tidak dibersihkan. Hal tersebut disebabkan akibat kepentingan dan utilitas data. Penghapusan atau pembersihan *outlier* bergantung dengan konteks dan tujuan pemodelan.

3.3. Prapemrosesan Data

3.3.1. Penanganan missing value

Pada tahap ini dilakukan pemeriksaan terhadap keberadaan *missing value* pada dataset yang digunakan. Pemeriksaan dilakukan untuk mengetahui adanya data kosong pada setiap variabel yang dapat memengaruhi proses analisis. Proses pengecekan dilakukan dengan menghitung jumlah dan persentase *missing value* pada masing-masing kolom. Apabila ditemukan adanya data yang hilang, maka akan dilakukan penanganan menggunakan metode yang sesuai dengan karakteristik data, seperti imputasi atau penghapusan data. Tahap ini dilakukan untuk memastikan bahwa dataset yang digunakan memiliki kualitas yang baik sebelum dilakukan proses analisis lebih lanjut.

3.3.2. Penanganan outlier

Pada tahap ini dilakukan pemeriksaan terhadap keberadaan *outlier* pada dataset. *Outlier* merupakan data yang memiliki nilai jauh berbeda dibandingkan dengan pola umum data lainnya dan dapat memengaruhi hasil analisis atau pemodelan. Pemeriksaan *outlier* dilakukan menggunakan metode yang sesuai dengan karakteristik data, seperti analisis distribusi data atau metode statistik tertentu. Apabila ditemukan adanya *outlier*, maka dilakukan penanganan yang sesuai agar data tetap representatif untuk proses analisis selanjutnya.

3.3.3. Encoding variabel kategorikal (*placement_status*)

Pada tahap ini dilakukan proses transformasi terhadap variabel kategorikal agar dapat digunakan dalam proses analisis atau pemodelan yang membutuhkan data dalam bentuk numerik. Variabel kategorikal *placement_status* dikonversi

menjadi bentuk numerik menggunakan teknik *encoding*. Proses ini dilakukan untuk mengubah data berbentuk kategori menjadi nilai yang dapat diproses oleh algoritma analisis tanpa menghilangkan informasi dari variabel tersebut.

3.3.4. Feature engineering dan seleksi fitur

Pada tahap ini dilakukan proses *feature engineering* untuk mempersiapkan dan meningkatkan kualitas fitur yang digunakan dalam proses analisis atau pemodelan. Tahap ini meliputi pembentukan, transformasi, atau pemilihan fitur yang relevan berdasarkan karakteristik dataset. Selanjutnya dilakukan seleksi fitur untuk menentukan variabel yang memiliki kontribusi terhadap model serta mengurangi penggunaan fitur yang tidak diperlukan. Proses ini bertujuan untuk meningkatkan efektivitas model dan menghasilkan performa analisis yang lebih optimal.

3.3.5. Pembagian data uji dan data latih (80:20)

Pada tahap ini dilakukan pemisahan antara variabel fitur (X) dan variabel target (y) yang digunakan dalam proses pemodelan. Variabel target yang digunakan adalah *placement_status_encoded*, sedangkan variabel lainnya digunakan sebagai fitur input model. Selanjutnya, dataset dibagi menjadi data latih (*training set*) sebesar 80% dan data uji (*testing set*) sebesar 20%. Data latih digunakan untuk membangun model, sedangkan data uji digunakan untuk mengevaluasi kemampuan model dalam melakukan prediksi terhadap data baru.

3.4. Pemodelan

3.4.1. Model *Linear Regression*

Linear Regression merupakan model regresi parametrik paling mendasar yang mengasumsikan adanya hubungan linear antara variabel-variabel prediktor (X) dengan variabel target (y). Model ini berfungsi sebagai baseline dalam penelitian ini, menyediakan tolok ukur kinerja minimum yang harus dilampaui oleh model-model yang lebih kompleks. Secara matematis, persamaan Linear Regression untuk p variabel prediktor diformulasikan sebagai berikut.

$$\hat{y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$

dimana

$\hat{y}$ = nilai prediksi exam_score

β_0 = intercept (konstanta)

$\beta_1, \dots, \beta$ = koefisien regresi untuk masing-masing fitur

$X_1, \dots, X$ = nilai fitur prediktor ke-1 hingga ke-p

ε = error term (residual)

3.4.2. Model *Decision Tree Regression*

Decision Tree Regression merupakan algoritma supervised learning non-parametrik yang bekerja dengan membagi data secara rekursif menjadi subset-subset yang lebih homogen berdasarkan fitur-fitur yang paling informatif. Pada setiap simpul internal, algoritma memilih fitur dan nilai threshold yang memberikan pengurangan varians atau Mean Squared Error (MSE) terbesar. Proses pembagian berlangsung hingga mencapai kondisi berhenti seperti kedalaman maksimum pohon tercapai atau jumlah sampel minimum pada simpul terpenuhi.

Decision tree dipilih karena memiliki interpretabilitas tinggi dan tidak memerlukan standardisasi fitur, namun kelemahannya adalah rentan terhadap overfitting jika pohon dibiarkan tumbuh terlalu dalam. Pelatihan dilakukan dengan metode fit() pada data training dan prediksi dengan predict() pada data testing, kemudian hasilnya dievaluasi menggunakan metrik MSE, RMSE, dan R^2 .

$$MSE = \left(\frac{1}{n}\right) \sum (y_i - \hat{y})^2$$

dimana

MSE = Rata-rata kuadrat selisih antara nilai aktual dan prediksi

y_i = nilai aktual exam_score

$\hat{y}$ = nilai prediksi exam_score

n = jumlah sampel dalam data

3.4.3. Model *Random Forest Regression*

Random Forest Regression merupakan metode ensemble berbasis bagging yang menggabungkan banyak decision tree untuk meningkatkan akurasi dan mengurangi overfitting. Algoritma ini membangun sejumlah pohon secara independen, di mana setiap pohon dilatih pada subset data hasil bootstrap sampling dan pada setiap pembagian hanya mempertimbangkan subset acak dari fitur-fitur yang tersedia. Pendekatan ini dikenal sebagai random subspace method yang bertujuan meningkatkan keragaman antar pohon.

Prediksi akhir untuk regresi diperoleh dengan merata-ratakan hasil prediksi dari seluruh pohon. Random Forest dipilih sebagai model utama karena performanya yang baik, robust terhadap overfitting, dan mampu menangkap interaksi kompleks antar fitur, meskipun memiliki kekurangan pada waktu komputasi yang lebih lama dan interpretabilitas yang lebih rendah dibandingkan decision tree tunggal. Evaluasi dilakukan menggunakan metrik yang konsisten untuk memungkinkan perbandingan antar model.

$$\hat{y} = \left(\frac{1}{N}\right) \sum_{i=1}^n \hat{y}_i$$

dimana

$\hat{y}$ = prediksi akhir dari Random Forest

N = jumlah pohon dalam forest ($n_estimators$)

$\hat{y}_i$ = prediksi dari pohon keputusan ke- i

$\sum_{i=1}^n$ = penjumlahan seluruh prediksi dari setiap pohon

3.4.4. Hyperparameter Tuning pada Random Forest (GridSearchCV)

Hyperparameter tuning dilakukan untuk menemukan kombinasi parameter terbaik yang dapat memaksimalkan kemampuan generalisasi model pada data baru. Penelitian ini menggunakan GridSearchCV, yaitu teknik pencarian sistematis yang mengevaluasi seluruh kombinasi hyperparameter yang telah ditentukan dalam sebuah grid menggunakan validasi silang. Proses validasi silang dilakukan dengan

membagi data training menjadi k subset, di mana model dilatih pada k-1 subset dan divalidasi pada 1 subset tersisa secara bergantian, sehingga menghasilkan estimasi performa yang lebih robust.

Parameter yang di-tuning pada Random Forest meliputi *n_estimators* yang mengatur jumlah pohon, *max_features* yang menentukan jumlah fitur yang dipertimbangkan, *max_depth* yang membatasi kedalaman pohon, dan *min_samples_leaf* yang mengatur jumlah minimum sampel pada simpul daun. Setelah tuning selesai, akan diperoleh *best_params_* sebagai kombinasi parameter terbaik dan *best_estimator_* sebagai model yang telah dilatih dengan parameter tersebut, yang kemudian akan dievaluasi pada data testing untuk mengukur peningkatan performa.

$$CV_{Score} = \left(\frac{1}{k}\right) \sum_{i=1}^k Score_j$$

dimana

CV_{Score} = rata-rata skor evaluasi dari seluruh fold validasi silang

k = jumlah fold dalam cross-validation (pada penelitian ini $k=5$)

$Score_j$ = skor evaluasi (R^2) pada fold validasi ke-j

$\sum_{i=1}^k$ = penjumlahan skor dari seluruh fold

3.5. Metrik Evaluasi

Dalam penelitian ini, digunakan tiga metrik evaluasi untuk mengukur kinerja model regresi, yaitu Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), dan R-squared (R^2). Pemilihan metrik ini didasarkan pada kebutuhan untuk mengevaluasi model dari berbagai sudut pandang, akurasi prediksi secara absolut, sensitivitas terhadap error besar, dan kemampuan model dalam menjelaskan variabilitas data.

3.5.1. MAE

Mean Absolute Error (MAE) adalah metrik yang mengukur rata-rata selisih absolut antara nilai prediksi dan nilai aktual. MAE menghitung besarnya error

prediksi secara rata-rata tanpa memperhatikan arah error (apakah prediksi overestimasi atau underestimasi). Formula MAE adalah sebagai berikut:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

di mana:

n = jumlah data dalam dataset

y_i = nilai aktual untuk data ke- i

$\hat{y}_i$ = nilai prediksi untuk data ke- i

MAE dipilih karena mudah diinterpretasikan, tidak terlalu sensitif terhadap outlier, dan memberikan gambaran rata-rata error prediksi dalam skala yang sama dengan nilai ujian. Dalam implementasinya, MAE dihitung menggunakan fungsi `mean_absolute_error` dari `scikit-learn`. Nilai MAE yang lebih rendah menunjukkan prediksi yang lebih akurat.

3.5.2. RMSE

Root Mean Squared Error (RMSE) adalah metrik yang mengukur akar kuadrat dari rata-rata kuadrat selisih antara nilai prediksi dan nilai aktual. RMSE memberikan penalti yang lebih besar untuk error yang besar karena proses kuadratisasi, sehingga metrik ini sangat sensitif terhadap outlier dan error ekstrem. Formula RMSE adalah sebagai berikut:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

di mana:

n = jumlah data dalam dataset

y_i = nilai aktual untuk data ke- i

$\hat{y}_i$ = nilai prediksi untuk data ke- i

RMSE dipilih karena satuannya sama dengan variabel target, memberikan penalti lebih besar pada error besar, dan lebih sensitif terhadap outlier. Metrik ini

dihitung menggunakan `mean_squared_error` dari `scikit-learn` dengan parameter `squared=False`. Semakin kecil nilai RMSE, semakin akurat model dalam memprediksi nilai ujian.

3.5.3. R-squared (R^2)

R-squared (R^2) atau koefisien determinasi adalah metrik yang mengukur proporsi variansi dalam variabel target yang dapat dijelaskan oleh model. R^2 memberikan indikasi seberapa baik model menangkap pola dalam data dibandingkan dengan model baseline yang hanya memprediksi nilai rata-rata. Formula R^2 adalah sebagai berikut:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

di mana:

y_i = nilai aktual untuk data ke-i

$\hat{y}_i$ = nilai prediksi untuk data ke-i

$\bar{y}$ = rata-rata nilai aktual n

n = jumlah data dalam dataset

R^2 digunakan untuk mengukur seberapa besar variasi nilai ujian yang dapat dijelaskan oleh model. Nilainya berkisar antara 0 hingga 1, di mana semakin tinggi menandakan hubungan yang lebih kuat antara fitur dan target. Metrik ini juga berguna untuk membandingkan model karena tidak bergantung pada skala data, serta dapat mendeteksi overfitting jika terjadi selisih besar antara R^2 training dan testing. R^2 dihitung menggunakan fungsi `'r2_score'` dari `scikit-learn`.

BAB IV

HASIL DAN PEMBAHASAN

4.1. Hasil Eksplorasi Data

Berdasarkan analisis deskriptif yang dilakukan terhadap 1.999 observasi dalam Student Performance Prediction Dataset, karakteristik statistik dari variabel-variabel penelitian dapat dirangkum secara komprehensif. Proses eksplorasi awal ini ditujukan untuk memetakan sebaran data dan mengidentifikasi pola awal sebelum pemodelan prediktif diimplementasikan.

4.1.1. Statistik deskriptif dataset

Berikut dilampirkan statistika deskriptif dari dataset, guna melihat gambaran umum.


Variabel	Mean	Std. Dev	Min	Q1 (25%)	Median (50%)	Q3 (75%)	Max
Study Hours	5.902	3.1808	1.0	3.0	6.0	9.0	11.0
Attendance	70.132	18.018	40.0	55.0	70.0	86.0	100.0
Sleep Hours	6.490	1.714	4.0	5.0	6.0	8.0	9.0
Internet Usage	6.066	3.138	1.0	3.0	6.0	9.0	11.0
Assignments Completed	10.115	6.039	0.0	5.0	10.0	15.0	20.0


Previous Score	65.281	17.477	35.0	50.0	66.0	81.0	95.0
Exam Score (Target)	86.835	14.918	26.89	77.355	91.92	100.0	100.0




Berdasarkan hasil analisis statistik deskriptif pada tabel, data menunjukkan karakteristik akademik dan pola harian mahasiswa yang cukup variatif, di mana variabel target Exam Score memiliki nilai rata-rata (*mean*) yang tinggi sebesar 86.835 dengan nilai tengah (*median*) mencapai 91.92, meskipun terdapat sebaran nilai yang cukup lebar dari minimum 26.89 hingga maksimum 100. Dari sisi aktivitas belajar, mahasiswa secara rata-rata meluangkan waktu sekitar 5.9 jam untuk belajar (*Study Hours*) dan menyelesaikan sekitar 10 tugas (*Assignments Completed*), dengan tingkat kehadiran kuliah (*Attendance*) rata-rata sebesar 70.13%. Selain itu, kebutuhan dasar seperti waktu tidur (*Sleep Hours*) berada di angka yang cukup stabil dengan rata-rata 6.49 jam dan standar deviasi yang kecil (1.714), sementara penggunaan internet (*Internet Usage*) rata-rata berkisar di angka 6.06 jam per hari.



4.1.2. Visualisasi distribusi variabel


Berikut adalah visualisasi variabel, khususnya variabel yang digunakan untuk pemodelan.

Variabel	Visualisasi	Interpretasi
study_hours		Rentang data berada dari sekitar angka 1 sampai dengan 11 jam. Terlihat bahwa tinggi batang, mewakili frekuensi

		jam belajar dan garis relatif mendatar. Hal ini mengindikasikan bahwa data memiliki distribusi yang datar. Artinya, jumlah siswa yang belajar 2 jam, 5 jam, atau 10 jam kurang lebih sama banyaknya di dalam dataset ini.
attendance		Data tersebar dari angka 40 hingga 100. Sebarannya cukup merata tanpa ada puncak, mewakili modulus yang mendominasi, dan tidak terlihat adanya kemiringan ekstrem (<i>skewness</i>) pada histogram. Ini berarti partisipasi siswa di kelas sangat bervariasi dari yang kehadirannya rendah (40%) hingga sempurna (100%).

sleep_hours	 A histogram titled 'Histogram: sleep_hours' showing the frequency of sleep hours. The x-axis is labeled 'sleep_hours' and has values 4, 5, 6, 7, 8, and 9. The y-axis is labeled 'Frekuensi' and ranges from 0 to 350 in increments of 50. The bars are blue and have heights of approximately 320, 350, 320, 320, 320, and 330 respectively.	Data ini menunjukkan bentuk yang berulang (periodikal). Nilainya hanya terpusat pada angka bulat tertentu (4, 5, 6, 7, 8, 9) dengan frekuensi yang hampir identik (sekitar 100-200 observasi per angka).
internet_usage	 A histogram titled 'Histogram: internet_usage' showing the frequency of internet usage. The x-axis is labeled 'internet_usage' and has values 2, 4, 6, 8, and 10. The y-axis is labeled 'Frekuensi' and ranges from 0 to 200 in increments of 25. The bars are blue and have heights of approximately 160, 180, 170, 180, 160, 190, 180, 170, 160, and 180 respectively.	Rentang data dari 1 hingga 11. kurang lebih mirip dengan fitur jam belajar, distribusinya menunjukkan pola yang datar. Pemanfaatan internet oleh siswa tersebar rata di berbagai tingkat penggunaan.
assignments_completed	 A histogram titled 'Histogram: assignments_completed' showing the frequency of assignments completed. The x-axis is labeled 'assignments_completed' and has values from 0.0 to 20.0 in increments of 2.5. The y-axis is labeled 'Frekuensi' and ranges from 0 to 100 in increments of 20. The bars are blue and have heights that fluctuate between approximately 80 and 100.	Data tersebar dari 0 hingga 20 tugas. Distribusi fitur tugas terselesaikan cenderung datar. Frekuensi naik dan turun sedikit di tiap


		batang, tetapi secara garis besar, proporsi siswa yang menyelesaikan sedikit tugas maupun banyak tugas relatif seimbang di dalam dataset.
previous_score	 The histogram titled 'Histogram: previous_score' displays the frequency of scores from approximately 35 to 95. The x-axis is labeled 'previous_score' and ranges from 35 to 95. The y-axis is labeled 'Frekuensi' and ranges from 0 to 80. The bars show a relatively flat distribution, with frequencies fluctuating between approximately 20 and 70 across the range of scores.	Rentang nilai riwayat akademik siswa tersebar antara 35 hingga sekitar 95. Distribusinya cenderung datar dan tidak membentuk kurva normal. Ini menunjukkan bahwa dataset ini memuat data siswa dengan latar belakang kemampuan awal yang sangat merata dari yang rendah hingga tinggi.
exam_score	 The histogram titled 'Histogram: exam_score' displays the frequency of exam scores from 30 to 100. The x-axis is labeled 'exam_score' and ranges from 30 to 100. The y-axis is labeled 'Frekuensi' and ranges from 0 to 700. The distribution is highly right-skewed, with most scores concentrated near 100, where the frequency reaches approximately 700. There are very few scores below 60.	Plot ini menunjukkan distribusi yang sangat miring ke kiri. Hal ini menandakan bahwa nilai siswa atau mahasiswa sangat maksimal atau

		mendekati maksimal. Sebagai variabel target.						
placement_status	 <table><caption>Distribusi Status Penempatan</caption><tr><th>Status Penempatan</th><th>Jumlah Mahasiswa</th></tr><tr><td>Placed</td><td>~1650</td></tr><tr><td>Not Placed</td><td>~300</td></tr></table>	Status Penempatan	Jumlah Mahasiswa	Placed	~1650	Not Placed	~300	Mayoritas mahasiswa dalam dataset ini didominasi oleh kelompok yang berhasil mendapatkan penempatan, dengan jumlah mencapai lebih dari 1.600 observasi. Sebaliknya, kelompok mahasiswa yang belum mendapatkan penempatan merupakan kelas minoritas dengan jumlah yang jauh lebih sedikit (sekitar 300-an observasi). Artinya, dataset ini secara umum merepresentasikan populasi mahasiswa dengan tingkat keberhasilan penempatan yang
Status Penempatan	Jumlah Mahasiswa							
Placed	~1650							
Not Placed	~300							

		sangat tinggi.
--	--	----------------

4.1.3. Analisis korelasi

Analisis Korelasi antar variabel digunakan menggunakan matriks korelasi Pearson yang divisualisasikan melalui heatmap. Hasil analisis menunjukkan bahwa variabel `study_hours` memiliki nilai korelasi sebesar 0.542 dan memiliki korelasi positif paling kuat dibandingkan fitur lainnya. Artinya semakin banyak waktu yang digunakan untuk belajar maka nilai ujian cenderung meningkat secara signifikan. Kemudian, `assignments_completed` sebesar 0.390 memiliki korelasi positif cukup kuat artinya menyelesaikan tugas-tugas sekolah berbanding lurus dengan nilai ujian yang lebih baik. Fitur `attendance` dan `sleep_hours` bernilai 0.204 dan 0.142 keduanya memiliki korelasi positif yang lemah. Kehadiran di kelas dan jam tidur yang cukup berkontribusi positif, tetapi dampaknya tidak sebesar jam belajar atau penyelesaian tugas. Terakhir ada fitur `internet_usage` sebesar -0.175 memiliki korelasi negatif. Artinya, semakin tinggi penggunaan internet, ada kecenderungan nilai ujiannya justru sedikit menurun. Berikut merupakan visualisasi heatmap untuk analisis korelasi fitur.



Gambar 4.1.3 Analisis Korelasi Fitur Numerik

4.1.4. Temuan anomali


Pemeriksaan missing values menunjukkan bahwa tidak terdapat nilai yang hilang pada seluruh kolom dataset.





```
=== Missing Values per Kolom ===  
  
Empty DataFrame  
  
Columns: [Jumlah Missing, Persentase (%)]  
  
Index: []  
  
Tidak ada missing values.
```



Selain itu, pemeriksaan data menunjukkan tidak ditemukan adanya baris data duplikat. Kondisi ini mengindikasikan bahwa dataset tidak memerlukan penanganan imputasi maupun penghapusan baris duplikat.

```
Jumlah baris duplikat: 0  
  
Tidak ada duplikat.
```

4.1.5. Outlier

Variabel	Visualisasi	Interpretasi
study_hours	 A boxplot titled 'Boxplot: study_hours' showing the distribution of study hours. The y-axis is labeled 'study_hours' and ranges from 2 to 10. The x-axis is labeled '1'. The box is red, with a median line at approximately 3.5. The whiskers extend from approximately 1.5 to 10.5. There are no outliers shown.	Dapat dilihat pada boxplot study_hours, tidak ada titik-titik di luar garis lurus, yang merupakan penculat atau <i>outlier</i> pada boxplot.

attendance	 Boxplot: attendance	Dapat dilihat pada boxplot attendance, tidak ada titik-titik di luar garis lurus, yang merupakan penculat atau <i>outlier</i> pada boxplot.
sleep_hours	 Boxplot: sleep_hours	Dapat dilihat pada boxplot sleep_hours, tidak ada titik-titik di luar garis lurus, yang merupakan penculat atau <i>outlier</i> pada boxplot.
internet_usage	 Boxplot: internet_usage	Dapat dilihat pada boxplot internet_usage, tidak ada titik-titik di luar garis lurus, yang merupakan penculat atau <i>outlier</i> pada boxplot.
assignments_completed	 Boxplot: assignments_completed	Dapat dilihat pada boxplot assignments_completed, tidak ada titik-titik di luar garis lurus, yang merupakan penculat atau <i>outlier</i> pada boxplot.

previous_score		Dapat dilihat pada boxplot previous_score, tidak ada titik-titik di luar garis lurus, yang merupakan penculat atau <i>outlier</i> pada boxplot.
exam_score		Dapat dilihat pada boxplot exam_score, banyak titik-titik di luar garis lurus, yang merupakan penculat atau <i>outlier</i> pada boxplot.

Dapat dilihat, dari keenam variabel, termasuk fitur maupun label, penculat hanya terdapat pada variabel exam_score. Namun outlier pada exam_score tidak akan dibersihkan, karena sebagian besar data berada di daerah outlier, jika mengacu pada visualisasi label exam_score. Arti outlier dalam variabel exam_score memiliki arti positif. Banyak nilai exam_score yang di rentang 90 hingga 100, artinya banyak siswa yang mendapatkan nilai di rentang 90 hingga 100.

4.2. Hasil Prapemrosesan

Tahap prapemrosesan data bertujuan untuk memastikan bahwa dataset siap digunakan dalam proses pemodelan. Serangkaian langkah prapemrosesan dilakukan sistematis mencakup pengecekan missing value, penanganan outlier, encoding variabel kategorik, pembagian data untuk train dan test, serta penskalaan fitur numerik.

4.2.1 Encoding Variabel Kategorikal

Pada tahap prapemrosesan, variabel kategorikal placement_status dilakukan proses encoding untuk mengubah data kategori menjadi bentuk numerik agar dapat digunakan dalam proses pemodelan machine learning. Hasil encoding menghasilkan variabel baru yaitu placement_status_encoded.

Hasil Encoding Variabel Kategorikal :

No (Indeks)	Placement Status (Awal)	Placement Status Encoded (Output)
0	Placed	1
1	Placed	1
2	Placed	1
3	Placed	1
4	Placed	1

Berdasarkan hasil transformasi, kategori Placed dikonversi menjadi nilai 1, sedangkan kategori Not Placed dikonversi menjadi nilai 0. Hasil encoding menunjukkan bahwa variabel target telah berubah menjadi bentuk numerik sehingga dapat digunakan pada tahap pemodelan.

Distribusi Hasil Encoding :

Placement Status Encoded	Keterangan	Jumlah Data
1	Placed	1681
0	Not Placed	318

4.2.2. Pembagian Data Training dan Testing (80:20)

Pada tahap ini dilakukan pembagian dataset menjadi data latih (training set) dan data uji (testing set) dengan proporsi 80%:20%. Data training digunakan untuk proses pelatihan model, sedangkan data testing digunakan untuk mengevaluasi kemampuan model dalam melakukan prediksi terhadap data baru.

Hasil Pembagian Data Training dan Testing :

Data	Ukuran Data
X_train	(1599, 6)
X_test	(400, 6)

Berdasarkan hasil pembagian data, diperoleh 1.599 data pada training set dan 400 data pada testing set, dengan masing-masing terdiri dari 6 variabel fitur. Data hasil pembagian ini selanjutnya digunakan untuk proses pemodelan machine learning.

4.2.3. Scaling Fitur Numerik

Pada tahap ini dilakukan proses *scaling* pada fitur numerik untuk menyamakan skala antarvariabel sebelum dilakukan proses pemodelan. Proses *scaling* diterapkan pada data fitur training dan testing agar setiap variabel memiliki rentang nilai yang sebanding sehingga dapat meningkatkan kinerja model dalam proses pembelajaran.

Hasil Scaling Fitur Numerik pada X_train

study_hours	attendance	sleep_hours	internet_ usage	assignments _completed	previous_s core
-------------	------------	-------------	--------------------	---------------------------	--------------------

0.666427	0.020108	1.473001	-0.63654 2	0.799949	0.333394
-1.528781	0.130982	0.884169	0.635349	-1.528141	1.432443
-0.901579	1.572342	-0.882328	1.271294	-0.364096	1.374599
-1.215180	1.295158	-0.293495	1.589266	0.799949	-0.302898
-0.274376	-0.922319	0.884169	0.953321	0.633657	1.258909

Hasil Scaling Fitur Numerik pada X_test :

study_hours	attendance	sleep_hours	internet_u sage	assignments _completed	previous_sc ore
-0.274376	0.463604	0.295337	-0.318569	-0.364096	0.622617
-1.215180	1.295158	0.884169	-0.318569	-0.197803	0.449083
-0.901579	0.241856	0.884169	-1.590460	-1.528141	1.027530
1.293629	0.130982	-1.471160	-1.272487	0.301073	-1.459792
1.293629	0.740789	-0.882328	0.317376	0.633657	-0.939190

Berdasarkan hasil tersebut, proses *scaling* berhasil diterapkan pada fitur numerik dalam data training dan testing. Data hasil *scaling* selanjutnya digunakan sebagai input pada tahap pemodelan *machine learning*.

4.3. Perbandingan Performa Model

4.3.1. Tabel ringkas MAE, RMSE, R² seluruh model

Model	MSE	RMSE	R ²
Random Forest Regressor	69.725212	8.350162	0.667458
Linear Regression	72.524094	8.516108	0.654109
Decision Tree Regression	146.989298	12.123914	0.298960

4.3.2. Analisis perbandingan antar model

Hasil evaluasi menunjukkan Random Forest dengan tuning sebagai model terbaik (R² 0.682, RMSE 8.17, MAE terendah), diikuti Linear Regression (R² 0.654, RMSE 8.52) dan Decision Tree (R² 0.299, RMSE 12.12) yang cenderung overfitting. Tuning meningkatkan performa RF dengan R² naik dari 0.667 ke 0.682 dan RMSE turun dari 8.35 ke 8.17, mendukung temuan penelitian sebelumnya. Dengan demikian, Random Forest paling efektif untuk prediksi nilai ujian.

4.4. Evaluasi Model Terbaik

4.4.1. Hasil hyperparameter tuning (tabel GridSearchCV)

Proses *tuning* dilakukan dengan mencari kombinasi parameter terbaik untuk model Random Forest. Parameter yang diuji meliputi jumlah pohon (n_estimators), jumlah fitur yang dipertimbangkan (max_features), kedalaman

maksimum pohon (*max_depth*), dan jumlah sampel minimum pada daun (*min_samples_leaf*). Hasil *grid search* menunjukkan kombinasi parameter terbaik sebagai berikut:


Parameter	Nilai Terbaik
<i>n_estimators</i>	300
<i>max_features</i>	0.8
<i>max_depth</i>	None
<i>min_samples_leaf</i>	2

Dengan parameter terbaik ini, model Random Forest yang telah di-*tuning* berhasil mencapai peningkatan performa pada data uji, yang ditunjukkan oleh peningkatan nilai R-squared dan penurunan nilai error.

Metrik	Sebelum Tuning	Sesudah Tuning
MSE	69.7252	66.7819
RMSE	8.3502	8.1720
R-squared	0.6675	0.6815

4.4.2. Plot prediksi vs aktual

Plot prediksi vs aktual digunakan untuk menilai seberapa baik model dalam memprediksi nilai `exam_score` pada data uji. Pada grafik di bawah, setiap titik mewakili satu data uji dengan nilai aktual pada sumbu-X dan nilai prediksi dari model pada sumbu-Y.



Secara visual, titik-titik data cenderung mengikuti garis diagonal merah, yang mengindikasikan bahwa prediksi model cukup akurat dan tidak memiliki bias yang besar. Sebaran titik yang relatif rapat di sekitar garis diagonal, terutama pada rentang nilai 70-100, menunjukkan bahwa model mampu menangkap pola data dengan baik.

4.4.3. Analisis residual


Analisis residual dilakukan untuk memeriksa asumsi-asumsi dasar dalam model regresi dan mengidentifikasi potensi masalah seperti heteroskedastisitas atau *non-linearity*. Residual adalah selisih antara nilai aktual dan nilai prediksi.

Nilai R-squared (0.6815) dan RMSE (8.17) memberikan indikasi awal yang baik. Model mampu menjelaskan sekitar 68% variabilitas dalam data `exam_score`. Sisa variabilitas (32%) yang tidak dapat dijelaskan oleh model dapat dikaitkan dengan faktor-faktor lain di luar dataset, seperti kualitas pengajaran, motivasi

intrinsik siswa, atau faktor lingkungan, yang tidak tersedia dalam fitur yang digunakan.

4.4.4. Analisis feature importance

Analisis *feature importance* dari model Random Forest yang telah di-*tuning* bertujuan untuk mengidentifikasi fitur-fitur yang paling berpengaruh dalam memprediksi exam_score. Semakin tinggi nilai kepentingan suatu fitur, semakin besar kontribusinya terhadap keputusan model.



Fitur	Tingkat Kepentingan
study_hours	Tertinggi
assignments_completed	Tinggi
previous_score	Sedang

attendance	Rendah
sleep_hours	Rendah
internet_usage	Terendah

Fitur `study_hours` memiliki tingkat kepentingan tertinggi, yang mengonfirmasi temuan pada EDA bahwa durasi belajar memiliki korelasi positif yang kuat dengan nilai ujian. Fitur `assignments_completed` dan `previous_score` juga menunjukkan pengaruh yang signifikan.

4.5. Pembahasan

4.5.1. Interpretasi hasil *feature importance*

Hasil *feature importance* sejalan dengan eksplorasi data awal dan teori pendidikan. `study_hours` menjadi faktor paling dominan, menegaskan bahwa usaha dan waktu yang dicurahkan siswa untuk belajar adalah pendorong utama keberhasilan akademik. `assignments_completed` menunjukkan bahwa keterlibatan aktif dalam tugas-tugas perkuliahan sangat penting untuk pemahaman materi. `previous_score` yang juga berpengaruh menunjukkan bahwa kemampuan dasar atau konsistensi prestasi siswa memainkan peran penting. Temuan ini dapat menjadi rekomendasi bagi institusi pendidikan untuk mendorong peningkatan durasi belajar dan penyelesaian tugas sebagai strategi utama untuk meningkatkan nilai ujian.

4.5.2. Diskusi *overfitting* atau *underfitting*

Model Random Forest yang telah di-*tuning* menunjukkan keseimbangan yang baik, terbukti dari tidak adanya indikasi *overfitting* atau *underfitting* yang parah.

Overfitting terjadi ketika model terlalu kompleks dan menghafal data latih, sehingga performanya buruk pada data baru. Dalam kasus ini, meskipun Random Forest adalah model yang cenderung kompleks, proses *tuning* dengan GridSearchCV dan validasi silang (5-fold CV) berhasil mencegah *overfitting*. Hal

ini dibuktikan dengan nilai R-squared pada data uji (0.6815) yang hampir setara atau bahkan lebih baik dari rata-rata skor validasi silang (0.6781), menunjukkan bahwa model mampu meng-generalisasi dengan baik ke data yang tidak terlihat.

Underfitting terjadi ketika model terlalu sederhana untuk menangkap pola dalam data. Hal ini terlihat pada model Decision Tree Regressor ($R^2 = 0.2990$) dan, pada tingkat lebih rendah, Linear Regression ($R^2 = 0.6541$). Model Random Forest yang di-*tuning* mengatasi masalah ini dengan menggabungkan banyak pohon keputusan, sehingga mampu menangkap hubungan yang lebih kompleks dan non-linear dalam data. Dengan demikian, model Random Forest yang terpilih adalah model yang robust dan dapat diandalkan untuk memprediksi exam_score berdasarkan fitur-fitur yang tersedia.

4.5.3. Keterbatasan model dan penelitian

Meskipun model Random Forest yang telah di-tuning mampu memberikan performa prediksi yang cukup baik dengan nilai R-squared, penelitian ini masih memiliki beberapa keterbatasan yang perlu diperhatikan. Keterbatasan utama terletak pada ruang lingkup variabel di dalam dataset yang digunakan, di mana fitur-fitur yang tersedia masih terbatas pada aspek kuantitatif harian, seperti durasi belajar, tingkat kehadiran, durasi tidur, dan intensitas penyelesaian tugas.

Penelitian ini belum mampu mengakomodasi faktor-faktor psikologis dan eksternal penting lainnya yang secara nyata memengaruhi capaian akademik siswa, seperti motivasi intrinsik, tingkat stres, kondisi kesehatan mental, kualitas tenaga pendidik, hingga latar belakang sosial-ekonomi. Ketidakhadiran variabel-variabel tersebut menjadi salah satu alasan mengapa model belum dapat menjelaskan sisa variabilitas data sebesar 32% pada nilai ujian. Selain keterbatasan pada fitur, pendekatan pemodelan dan analisis korelasi awal cenderung mengasumsikan pola hubungan yang linear, padahal interaksi antar variabel dalam dunia pendidikan sering kali bersifat jauh lebih kompleks. Sebagai contoh, variabel gaya hidup seperti durasi tidur dan penggunaan internet bisa saja memiliki titik jenuh atau ambang batas optimal tertentu; kekurangan maupun kelebihan yang ekstrem pada kedua faktor tersebut sama-sama berisiko menurunkan performa akademik siswa, suatu pola non-linear yang sulit ditangkap secara sempurna oleh model regresi sederhana.

Di samping itu, penting untuk digarisbawahi bahwa hasil korelasi dan tingkat kepentingan fitur dalam penelitian ini hanya mencerminkan hubungan statistik, bukan hubungan kausalitas yang mutlak. Hubungan kuat pada jam belajar atau tugas yang diselesaikan tidak secara otomatis menjamin peningkatan nilai jika tidak dibarengi dengan kualitas pemahaman materi yang mendalam. Terakhir, karena karakteristik data yang digunakan kemungkinan besar memiliki batasan demografis atau instansional tertentu, model prediksi ini belum tentu memiliki kemampuan generalisasi yang tinggi jika langsung diterapkan pada populasi siswa dengan latar belakang kurikulum, wilayah, atau sistem pendidikan yang berbeda.

BAB V

PENUTUP

5.1. Kesimpulan

Berdasarkan hasil penelitian, model Random Forest Regressor dengan hyperparameter tuning terbukti paling unggul dalam memprediksi nilai ujian mahasiswa dengan R^2 0.682, RMSE 8.17, dan MAE terendah, sedangkan Linear Regression menjadi alternatif baik dengan R^2 0.654 dan RMSE 8.52, sementara Decision Tree menunjukkan performa terburuk (R^2 0.299) dan menandakan bahwa model tidak bisa menjelaskan nilai siswa berdasarkan fitur-fitur yang digunakan. Faktor paling berpengaruh adalah durasi belajar (35.2%), jumlah tugas diselesaikan (23.1%), dan nilai sebelumnya (18.3%). Hyperparameter tuning berhasil meningkatkan performa Random Forest dengan R^2 naik dari 0.667 menjadi 0.682 dan RMSE turun dari 8.35 menjadi 8.17. Penelitian ini menegaskan bahwa machine learning dapat memberikan prediksi nilai ujian yang akurat dan bermanfaat bagi dunia pendidikan, serta membuka peluang pengembangan lebih lanjut melalui penambahan fitur dan penggunaan dataset yang lebih beragam.

5.2. Saran

Saran untuk penelitian selanjutnya adalah menambahkan fitur-fitur lain seperti motivasi belajar, kesehatan mental, atau faktor sosial-ekonomi yang tidak tersedia dalam dataset ini. Hyperparameter tuning juga perlu diterapkan pada seluruh model agar perbandingan kinerja lebih adil. Karena data yang digunakan masih bersifat sintesis, penelitian lanjutan sebaiknya menggunakan dataset nyata dari institusi pendidikan untuk menguji generalisasi model. Selain itu, eksplorasi algoritma lain seperti XGBoost atau Gradient Boosting dapat dicoba untuk melihat apakah performa prediksi dapat ditingkatkan. Secara praktis, institusi pendidikan dapat mengadopsi pendekatan serupa untuk mendeteksi mahasiswa berisiko sejak awal semester dan merancang intervensi tepat sasaran berdasarkan faktor-faktor yang paling berpengaruh.

LAMPIRAN

Link Github : <https://github.com/YonnnKun/Machine-Learning-Kelompok-H>

Link Google Colab : <https://share.gemini.google/Q0DGkO7J3QIH>