

Machine Learning

Analisis Nilai Ujian Siswa Menggunakan Pendekatan Machine Learning


Kelompok H

UNSOED

25 Juni 2026

Nama Kelompok

- Verdina Tista Pudyawardhana (K1D024002)
- Nabila Alsa Haryanto (K1D024006)
- Frisca Putri Aulia (K1D024008)
- Wuri Dwi Ariyanti (K1D024025)
- Dionisius Antoni Pratama (K1D024031)



Latar Belakang

Teknologi Machine Learning kini digunakan secara strategis untuk pemodelan prediktif guna mengukur dan mengoptimalkan prestasi akademik siswa.

Prediksi nilai sejak dini membantu institusi mengidentifikasi siswa yang berisiko lebih cepat, sehingga intervensi (seperti bimbingan tambahan) bisa diberikan sebelum ujian akhir.

Penelitian menggunakan dataset 1.999 siswa dengan algoritma Random Forest untuk menghasilkan prediksi yang kuat serta memetakan faktor yang paling dominan (feature importance)

Prestasi siswa dipengaruhi oleh variabel yang saling terkait, mulai dari aspek akademis (jam belajar, kehadiran, tugas) hingga gaya hidup digital (jam tidur, penggunaan internet).

Tinjauan Dataset

Nama Dataset : Student Performance Prediction Dataset

Sumber Dataset : Kaggle

Nama Fitur	Tipe	Deskripsi
study_hours	Numerik	Jumlah jam belajar per hari
attendance	Numerik	Persentase kehadiran mahasiswa
sleep_hours	Numerik	Durasi tidur per hari (jam)
internet_usage	Numerik	Penggunaan internet (jam/hari)
assignments_completed	Numerik	Jumlah tugas yang diselesaikan
previous_score	Numerik	Nilai ujian sebelumnya
placement_status	Kategorik	Status penempatan kerja (Placed/Not Placed)
exam_score	Numerik (Target)	Nilai ujian akhir (variabel yang diprediksi)


Statistik Deskriptif

Variabel	Mean	Std. Dev	Min	Q1 (25%)	Median (50%)	Q3 (75%)	Max
Study Hours	5.902	3.1808	1.0	3.0	6.0	9.0	11.0
Attendance	70.132	18.018	40.0	55.0	70.0	86.0	100.0
Sleep Hours	6.490	1.714	4.0	5.0	6.0	8.0	9.0
Internet Usage	6.066	3.138	1.0	3.0	6.0	9.0	11.0
Assignments Completed	10.115	6.039	0.0	5.0	10.0	15.0	20.0
Previous Score	65.281	17.477	35.0	50.0	66.0	81.0	95.0
Exam Score (Target)	86.835	14.918	26.89	77.355	91.92	100.0	100.0

Menggunakan `df.describe()` untuk melihat statistik deskriptif. Data menunjukkan karakteristik akademik dan pola harian mahasiswa yang cukup variatif,


- Exam Score memiliki nilai rata-rata (mean) yang tinggi sebesar 86.835 dengan nilai tengah (median) mencapai 91.92, meskipun terdapat sebaran nilai yang cukup lebar dari minimum 26.89 hingga maksimum 100.
- Dari sisi aktivitas belajar, mahasiswa secara rata-rata meluangkan waktu sekitar 5.9 jam untuk belajar (Study Hours)
- Siswa menyelesaikan sekitar 10 tugas (Assignments Completed)
- dengan tingkat kehadiran kuliah (Attendance) rata-rata sebesar 70.13%.
- waktu tidur (Sleep Hours) berada di angka yang cukup stabil dengan rata-rata 6.49 jam dan standar deviasi yang kecil (1.714).
- penggunaan internet (Internet Usage) rata-rata berkisar di angka 6.06 jam per hari

Visualisasi



Pada visualisasi dan distribusi data, hampir seluruh data berbentuk datar. Dapat dilihat pada contohnya `assignment_completed` (tugas yang dikumpulkan), memiliki distribusi yang datar. Kecuali pada nilai ujian siswa, memiliki ekor yang sangat miring ke kiri, data terpusat di kanan. Ini memiliki arti yang positif karena nilai tersebar di antara 90 hingga 100.

Deteksi Outlier




Dapat dilihat, dari keenam variabel, termasuk fitur maupun label, pencilat hanya terdapat pada variabel exam_score. Namun outlier pada exam_score tidak akan dibersihkan, karena sebagian besar data berada di daerah outlier, jika mengacu pada visualisasi label exam_score. Arti outlier dalam variabel exam_score memiliki arti positif. Banyak nilai exam_score yang di rentang 90 hingga 100, artinya banyak siswa yang mendapatkan nilai di rentang 90 hingga 100.

Korelasi Fitur

```
corr_cols = ['study_hours', 'attendance',
             'sleep_hours', 'internet_usage',
             'assignments_completed', 'previous_score',
             'exam_score']
corr_matrix = df[corr_cols].corr()

plt.figure(figsize=(8, 6))
mask = np.triu(np.ones_like(corr_matrix, dtype=bool))
sns.heatmap(corr_matrix, annot=True, fmt='.3f', cmap='RdYlGn',
            center=0, mask=mask, linewidths=0.5,
            annot_kws={'size': 12, 'weight': 'bold'})
plt.title('Heatmap Korelasi Fitur Numerik', fontsize=14, fontweight='bold')
plt.tight_layout()
plt.show()
```

- **Korelasi Terkuat:** `study_hours` punya korelasi positif paling kuat dengan `exam_score` (0.542). Makin lama belajar, nilai ujian cenderung makin tinggi.
- **Faktor Pendukung Nilai:** `assignments_completed` (0.390) dan `previous_score` (0.306) juga punya korelasi positif yang cukup signifikan dengan `exam_score`.
- **Korelasi Negatif:** `internet_usage` punya korelasi negatif dengan `exam_score` (-0.175). Artinya, makin tinggi penggunaan internet, ada kecenderungan nilai ujian sedikit menurun.
- **Hubungan Antar Fitur Lain:** Selain dengan `exam_score`, hampir semua fitur numerik lainnya (seperti hubungan antara `sleep_hours`, `attendance`, dll.) memiliki nilai korelasi yang sangat mendekati nol, menandakan tidak ada hubungan linear yang berarti di antara mereka.



Prapemrosesan Data

MISSING VALUE

```
=== Missing Values per Kolom ===  
Empty DataFrame  
Columns: [Jumlah Missing, Persentase (%)]  
Index: []
```



Tidak ada missing values.

Dilakukan pengecekan missing value untuk memastikan kelengkapan data sebelum proses pemodelan. Berdasarkan hasil pemeriksaan, tidak ditemukan adanya missing value pada dataset, sehingga seluruh data dapat digunakan untuk tahap analisis selanjutnya.

PEMISAHAN DATA (TRAINING & TESTING)

```
Ukuran Training Set (X_train): (1599, 6)  
Ukuran Testing Set (X_test): (400, 6)
```

SCALING FITUR NUMERIK

	study_hours	attendance	sleep_hours	internet_usage	assignments_completed	previous_score
240	0.666427	0.020108	1.473001	-0.636542	0.799949	0.333394
812	-1.528781	0.130982	0.884169	0.636349	-1.528141	1.432443
1824	-0.901579	1.572342	-0.882328	1.271294	-0.364096	1.374599
1244	-1.215180	1.295158	-0.293495	1.589266	0.799949	-0.302898
1084	-0.274376	-0.922319	0.884169	0.963321	0.633657	1.258909
fitur numerik pada X_test telah di-scale:						
	study_hours	attendance	sleep_hours	internet_usage	assignments_completed	previous_score
256	-0.274376	0.463604	0.295337	-0.318569	-0.364096	0.622617
352	-1.215180	1.295158	0.884169	-0.318569	-0.197803	0.449083
298	-0.901579	0.241856	0.884169	-1.590460	-1.528141	1.027530
581	1.293629	0.130982	-1.471160	-1.272487	0.301073	-1.459792

Dilakukan proses scaling pada fitur numerik untuk menyamakan skala data sebelum pemodelan. Berdasarkan hasil proses tersebut, fitur numerik pada data X_train dan X_test telah berhasil di-scale sehingga data siap digunakan dalam proses pemodelan.

Dilakukan pembagian dataset menjadi data training dan testing dengan rasio 80:20 untuk proses pelatihan dan evaluasi model. Berdasarkan hasil pembagian, diperoleh X_train sebesar (1599, 6) dan X_test sebesar (400, 6) sehingga data siap digunakan pada tahap analisis dan pemodelan selanjutnya.

Pemodelan

Regresi Linear

```
# Inisialisasi Model
lin_reg = LinearRegression()

# Latih Model
lin_reg.fit(X_train, y_train)

# Prediksi pada Testing Set
y_pred_lin_reg = lin_reg.predict(X_test)

# Evaluasi Model
mse_lin_reg = mean_squared_error(y_test, y_pred_lin_reg)
rmse_lin_reg = np.sqrt(mse_lin_reg)
r2_lin_reg = r2_score(y_test, y_pred_lin_reg)
```

Output:

```
=== Evaluasi Model Regresi Linear ===
Mean Squared Error (MSE) : 72.5241
Root Mean Squared Error (RMSE): 8.5161
R-squared (R2) : 0.6541
```

Linear Regression mampu menjelaskan **65.4%** variasi nilai ujian dengan error rata-rata sekitar **8.52** poin. Artinya, model ini cukup baik untuk prediksi sederhana, namun karena hubungan antara fitur dan nilai ujian mungkin tidak sepenuhnya linear, performanya masih di bawah Random Forest.

Decision Tree Regressor

```
# Inisialisasi Model
dec_tree_reg = DecisionTreeRegressor(random_state=42)

# Latih Model
dec_tree_reg.fit(X_train, y_train)

# Prediksi pada Testing Set
y_pred_dec_tree = dec_tree_reg.predict(X_test)

# Evaluasi Model
mse_dec_tree = mean_squared_error(y_test, y_pred_dec_tree)
rmse_dec_tree = np.sqrt(mse_dec_tree)
r2_dec_tree = r2_score(y_test, y_pred_dec_tree)
```

Output:

```
=== Evaluasi Model Decision Tree Regressor ===
Mean Squared Error (MSE) : 146.9893
Root Mean Squared Error (RMSE): 12.1239
R-squared (R2) : 0.2990
```

Decision Tree hanya mampu menjelaskan **29.9%** variasi data dengan error rata-rata **12.12** poin. Performa buruk ini disebabkan oleh overfitting, di mana model terlalu kompleks dan menghafal pola pada data training sehingga gagal menggeneralisasi dengan baik pada data baru.

Random Forest Regressor

```
# Inisialisasi Model
rf_reg = RandomForestRegressor(random_state=42)

# Latih Model
rf_reg.fit(X_train, y_train)

# Prediksi pada Testing Set
y_pred_rf = rf_reg.predict(X_test)

# Evaluasi Model
mse_rf = mean_squared_error(y_test, y_pred_rf)
rmse_rf = np.sqrt(mse_rf)
r2_rf = r2_score(y_test, y_pred_rf)
```

Output:

```
=== Evaluasi Model Random Forest Regressor ===
Mean Squared Error (MSE) : 69.7252
Root Mean Squared Error (RMSE): 8.3502
R-squared (R2) : 0.6675
```

Random Forest bekerja dengan membangun banyak decision tree secara paralel dan menggabungkan hasil prediksinya, sehingga lebih stabil dan tidak mudah overfitting. Hasilnya, model ini mencapai R^2 **0.667** dan RMSE **8.35**, menjadikannya model terbaik di antara ketiganya.

Penggunaan Hyperparameter

Proses tuning dilakukan dengan mencari kombinasi parameter terbaik untuk model Random Forest. Parameter yang diuji meliputi jumlah pohon (`n_estimators`), jumlah fitur yang dipertimbangkan (`max_features`), kedalaman maksimum pohon (`max_depth`), dan jumlah sampel minimum pada daun (`min_samples_leaf`).

Hasil grid search menunjukkan kombinasi parameter terbaik `n_estimators 300 max_features 0.8 max_depth None min_samples_leaf 3`. Dengan parameter terbaik ini, model Random Forest yang telah di-tuning berhasil mencapai peningkatan performa pada data uji, yang ditunjukkan oleh peningkatan nilai R-squared dan penurunan nilai error.


Metrik	Sebelum Tuning	Sesudah Tuning
MSE	69.7252	66.7819
RMSE	8.3502	8.1720
R-squared	0.6675	0.6815

Evaluasi Model

Model	MSE	RMSE	R2
Random Forest Regressor	69.725212	8.350162	0.667458
Linear Regression	72.524094	8.516108	0.654109
Decision Tree Regressor	146.989298	12.123914	0.298960
Random Forest Regressor (Tuned)	66.7819	8.1720	0.6815

Hasil evaluasi menunjukkan Random Forest dengan tuning sebagai model terbaik dengan R^2 0.682 dan RMSE 8.17, diikuti Linear Regression (R^2 0.654, RMSE 8.52), sementara Decision Tree menunjukkan performa terburuk (R^2 0.299) dan cenderung overfitting. Tuning berhasil meningkatkan R^2 Random Forest dari 0.667 menjadi 0.682 serta menurunkan RMSE dari 8.35 menjadi 8.17. Dengan demikian, Random Forest dengan tuning paling efektif untuk memprediksi nilai ujian mahasiswa

Feature Importance



Feature importance menunjukkan durasi belajar (35.2%) sebagai faktor paling dominan, diikuti jumlah tugas (23.1%) dan nilai sebelumnya (18.3%), sementara penggunaan internet justru berkorelasi negatif. Hal ini menekankan bahwa upaya peningkatan nilai ujian sebaiknya difokuskan pada optimalisasi waktu belajar dan penyelesaian tugas.

Feature	Importance
study_hours	35,2%
assignments_completed	23,1%
previous_score	18,3%
attendance	10,0%
sleep_hours	6,8%
internet_usage	6,6%

Kesimpulan

Kesimpulan

Berdasarkan hasil penelitian, model Random Forest Regressor dengan hyperparameter tuning terbukti paling unggul dalam memprediksi nilai ujian mahasiswa dengan R^2 0.682, RMSE 8.17, dan MAE terendah, sedangkan Linear Regression menjadi alternatif baik dengan R^2 0.654 dan RMSE 8.52, sementara Decision Tree menunjukkan performa terburuk (R^2 0.299) dan menandakan bahwa model tidak bisa menjelaskan nilai siswa berdasarkan fitur-fitur yang digunakan. Faktor paling berpengaruh adalah durasi belajar (35.2%), jumlah tugas diselesaikan (23.1%), dan nilai sebelumnya (18.3%). Hyperparameter tuning berhasil meningkatkan performa Random Forest dengan R^2 naik dari 0.667 menjadi 0.682 dan RMSE turun dari 8.35 menjadi 8.17. Penelitian ini menegaskan bahwa machine learning dapat memberikan prediksi nilai ujian yang akurat dan bermanfaat bagi dunia pendidikan, serta membuka peluang pengembangan lebih lanjut melalui penambahan fitur dan penggunaan dataset yang lebih beragam.

Saran

Saran untuk penelitian selanjutnya adalah menambahkan fitur-fitur lain seperti motivasi belajar, kesehatan mental, atau faktor sosial-ekonomi yang tidak tersedia dalam dataset ini. Hyperparameter tuning juga perlu diterapkan pada seluruh model agar perbandingan kinerja lebih adil. Karena data yang digunakan masih bersifat sintesis, penelitian lanjutan sebaiknya menggunakan dataset nyata dari institusi pendidikan untuk menguji generalisasi model. Selain itu, eksplorasi algoritma lain seperti XGBoost atau Gradient Boosting dapat dicoba untuk melihat apakah performa prediksi dapat ditingkatkan. Secara praktis, institusi pendidikan dapat mengadopsi pendekatan serupa untuk mendeteksi mahasiswa berisiko sejak awal semester dan merancang intervensi tepat sasaran berdasarkan faktor-faktor yang paling berpengaruh.